Peut-on faire confiance aux IA génératives pour déléguer les analyses de cycle de vie ? Benchmark de 7 modèles génératifs accessibles

000120

Protzenko D. [1], Constans J. [1], Plan A. [1]
dorian.protzenko@gmail.com
(1) PUI, CHICAS, Gap

Contexte

- L'impact écologique est devenu un élément central dans la pratique hospitalière (marchés, optimisation des prescriptions, logistique...).
- L'analyse de cycle de vie, permettant d'estimer cet impact, s'avère complexe, et trop chronophage pour généraliser son implémentation en routine.

Nous avons souhaité évaluer la performance des LLM par rapport aux méthodes de références, afin d'évaluer si leur usage peut être d'intérêt dans cette thématique.

Méthode

- Sélection de 11 molécules issues d'une analyse précédente.

- Estimation de leur impact via 6 LLM classiques (ChatGPT 5.2, Gemini 3, Claude Opus 4.5, Mistral, Grok 4.1, DeepSeek) et 1 LLM spécialisé (MedGPT beta → non fonctionnel).

- Comparaison à la méthode de référence DGOS (Ecovamed).

Résultats

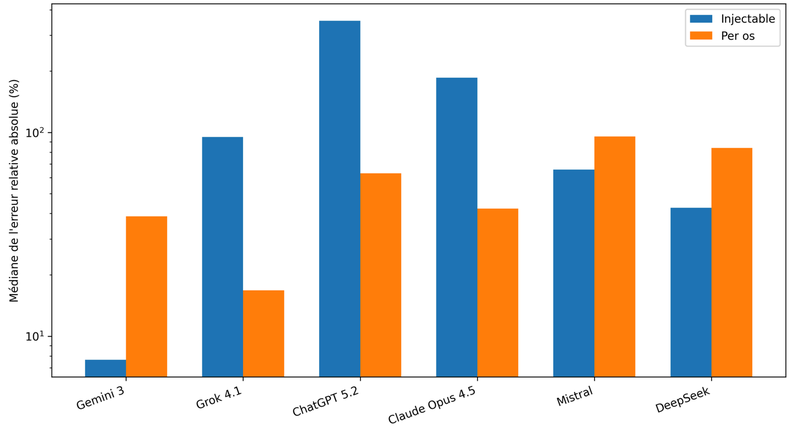

Figure 1 : Performance des modèles selon la voie d'administration

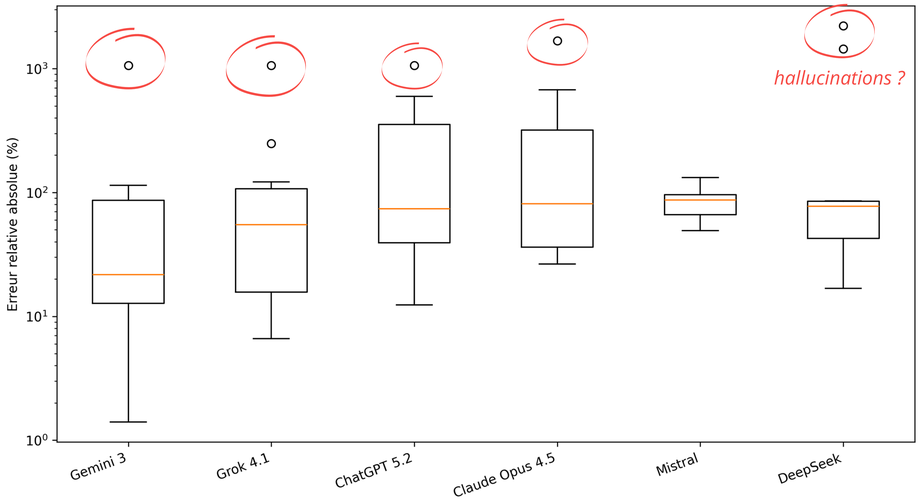

Figure 2 : Erreur de chaque modèle (log log scale)

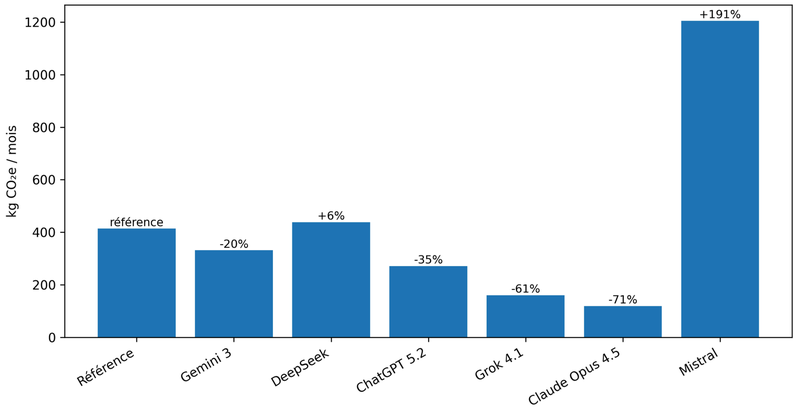

Figure 3 : Impact simulé de l'erreur sur 1000 délivrances

Gemini

→ meilleur sur injectables et robustesse globale (s'est appuyé sur 7 sources pour ses estimations, contre 0 à 1 pour les autres)

Grok

→ meilleur sur per os mais instable

deepseek

→ bon en agrégé mais trompeur (fortuit ?)

Conclusion

Les LLM peuvent accélérer le repérage des ordres de grandeur en ACV médicamenteuse, mais **leur variabilité et leurs erreurs extrêmes imposent un contrôle humain systématique**. À terme, leur intégration dans les outils de prescription pourrait permettre une **visualisation** en temps réel de **l'impact environnemental**, sous réserve de modèles validés et traçables.